

1-6日汇报

Debiasing Career Recommendations with Neural Fair Collaborative Filtering

偏差类型积累，方便找到新的偏差：

1. bias in the input embeddings due to the non-sensitive items,
2. bias in the prediction outputs due to the sensitive items.
3. 物品不会在很长时间内受欢迎；用户的喜欢也会随着时间变化

使用CF **嵌入**来去除 **性别偏差**：CF embeddings for users from each protected group

权重: $w' = w - (w \cdot v_B)v_B$

女性用户偏差方向: $v_{female} = \frac{1}{n_f}(f_1 + f_2 + \dots + f_n)$, f_1, f_2, \dots, f_n are vectors for each female user

整体性别偏差向量: $v_B = \frac{v_{female} - v_{male}}{\|v_{female} - v_{male}\|}$

对用户向量进行去偏: $p'_u = p_u - (p_u \cdot v_B)v_B$, p_u is user vector.

上面这些是性别去偏。

然后用一个 **fairness penalty** 来去掉 **sensitive items** 中的人口统计偏差, *eg. more men than women choose computer science careers.*

Self-Guided Learning to Denoise for Robust Recommendation

样本选择 和 样本重新加权 **sample selection methods** and **sample re-weighting methods**

样本选择严重依赖 **样本分布**

样本重新加权也有如下限制：

- **Abandon of Hard Clean Interactions**: 一些干净的互动可能有很高的损失值，因此在重新加权的過程中被抛弃了 *aka.* hard yet clean interactions
- **Lack of Adaptivity and Universality**: 缺乏适应性和普遍性

SGDL分为两个时期：记忆期和自我主导学习期

在训练的早期阶段，被记忆的数据大多是容易和干净的交互，我们把它们作为去噪信号来收集，以指导接下来的去噪训练过程

Interpolative Distillation for Unifying Biased and Debiased Recommendation

现有的策略：

- data imputation：评估缺失数据的影响，减少选择偏差
- regularization：引入正则化减少推荐列表的偏差
- causal inference：两个经典的因果框架potential outcome、structural causal models

分成两种环境（现实环境bias & 非现实环境debias,并且 $D_b \gg D_d$ ），计算对于一个特定的 user-item pair，属于每一种环境的概率： $P(E | U, I)$ 。在以往的推荐模型中 只考虑了一种环境，也就是现实环境，并没有考虑非现实环境。

用 $P(R | U, I, E)$ & $P(E | U, I)$ 来估算 $P(R | U, I)$:

$$P(R|U, I) = \sum_E P(E|U, I, R) \cdot P(E|U, I)$$

4.2

4.2.1

使用 biased and debiased model 训练得到最优参数，然后预测出 \hat{r}_b, \hat{r}_d 以此来得到 $P(R|U, I, E = eb)$ 和 $P(R|U, I, E = ed)$

4.2.2

如果 given (u,i) pair 更可能属于哪一种环境，那么相应的 \hat{r}_b or \hat{r}_d 就会更接近真实的 r 。
 \hat{r}_b and \hat{r}_d 都是在各自环境中表现的最好的算法得到的。 \hat{r}_d 是 $P(R|U, I, E = eb)$ 的估计期望值，越接近期望就意味着 r 有更大的可能性 comes from $P(R|U, I, E = eb)$ ，那么因此 $P(E = ed|U, I)$ 应该会更大。

$$w_b = \frac{L_b(\bar{r}_b, r)\gamma}{L_b(\bar{r}_b, r)\gamma + L_d(\bar{r}_d, r)\gamma} \quad w_d = \frac{L_d(\bar{r}_d, r)\gamma}{L_b(\bar{r}_b, r)\gamma + L_d(\bar{r}_d, r)\gamma}$$

γ is a negative value, 保证 $L_b(\bar{r}_b, r)$ 越小时, w_b 越大, 说明当 \bar{r}_b 越接近 r 时, w_b 越大。

4.2.3

r_* 是 $P(R|U, I)$ 的期望, $r_* = w_b \bar{r}_b + w_d \bar{r}_d$

然后在两个训练集（包括biased和debiased）上训练新的模型，新模型的损失函数是让训练结果和 r_* 做比较，并不是观察的评分 r 。

4.2.4 纳入未观察到的数据

使用 $\mathcal{D}_n = \mathcal{U} \times \mathcal{I} - \mathcal{D}_b \cup \mathcal{D}_d$ 来表示未观察的数据。

w'_b and w'_d 表示 $P(E = eb|U, I)$ and $P(E = ed|U, I)$ 的插值

$$r'_* = w'_b \bar{r}_b + w'_d \bar{r}_d$$

$$w'_b = \frac{L_b(\bar{r}_b, \bar{r})\gamma_2}{L_b(\bar{r}_b, \bar{r})\gamma_2 + L_d(\bar{r}_d, \bar{r})\gamma_2} \quad w'_d = \frac{L_d(\bar{r}_d, \bar{r})\gamma_2}{L_b(\bar{r}_b, \bar{r})\gamma_2 + L_d(\bar{r}_d, \bar{r})\gamma_2}$$

$L_b(\bar{r}_b, \bar{r})$ and $L_d(\bar{r}_d, \bar{r})$ is the distances between prediction of teachers and student.

模型为 $f_S(u, i; \theta)$ 使用模型的预测值和 r'_* 来作为损失函数的参数。

对模型进行训练，当损失函数最小时到超参数 θ 。

和其他算法的不同点：

- 同时利用了有偏模型和无偏模型
- 从两种模型中学习一个新的模型，能处理事实和反事实环境
- 使用了未观察的数据来训练 *student* 模型

5.3

受欢迎程度是用 *item* 在训练数据中出现的频次决定的。

在不受欢迎的 *item* 中，InterD 更相信 *debiased-teacher*，而在受欢迎的 *item* 中，InterD则更信赖 *biased-teacher*。

在 *top-20* 中，*AutoDebias* 推荐的项目 *less-popular* 占的比较多，*MF* 推荐的项目 *popular* 占的比较多

Yahoo! R3

拥有无偏评分数据的公开数据集：Yahoo! R3 和 Coat。

Yahoo! R3的训练集是 **MNAR**(missing not at random)，测试集是 **MCAR**(missing completely at random, no bias)。

MAR

missingness depend only on available information(例如依赖于年龄)

随机丢失意味着数据丢失的概率与丢失的数据本身无关，而仅与部分已观测到的数据(年龄)有关。也就是说，数据的缺失不是完全随机的，该类数据的缺失依赖于其他完全变量。

MNAR

missingness depend on unavailable information

有其他患者等待则抛硬币来决定记录与否，无其他患者等待则记录数据。但是否等待是无法观测、无法收集到的数据。

Yahoo! R3数据集还提供了一个使用**均匀策略**收集到的测试集：系统为5400位用户中的每个用户随机选取十首音乐作品，并要求该用户对这些音乐作品给予反馈。因此，Yahoo! R3的测试集可以被认为是完全随机缺失的（missing at complete random），即具有无偏性质。

本文仅选用Yahoo! R3数据集作为实验数据集是因为它是目前仅有的一个较大的，且提供在均匀策略下收集到的测试集的公开的推荐系统数据集。